Felipe P. dos Santos

Engenheiro de IA Sênior | Plataformas de LLM, RAG, agentes e GenAI aplicada
Curitiba, Brasil | santospefelipe@gmail.com | mefelipe.com.br | LinkedIn: felipepesantos

---

Resumo

Engenheiro de IA Sênior que leva GenAI aplicada à produção. Respondo pela plataforma de LLM dos produtos de IA da Unimed Goiânia (~400 mil beneficiários): modelos open source no vLLM em GPUs na AWS, gateway compatível com a OpenAI, observabilidade e fallback de modelos. Antes construí RAG e agentes no Grupo Boticário, liderei engenharia em startup e fundei um SaaS B2B (7.000+ usuários).

Experiência

Unimed Goiânia (via DeepDiveIA) | Engenheiro de IA Sênior (nov 2026 – atual)

- **Plataforma de LLM:** Respondo pela plataforma de LLM dos produtos de IA: modelo multimodal open source no vLLM (GPU na AWS) com gateway FastAPI compatível com a OpenAI (chave por app, quotas, fallback), busca híbrida (pgvector) e custo por chamada no Langfuse/Grafana.
- **Arquitetura e revisão técnica:** Autor da arquitetura-alvo (local-first, fallback pago no Brasil) e da revisão técnica: escolha de modelos para uma GPU de 24 GB, segurança pelo OWASP Top 10 para LLMs, LGPD para dados de saúde e roadmap priorizado antes da produção.
- **Integração com os produtos:** Apoio os times a integrar a plataforma em três produtos de IA em saúde: chat que analisa dashboards do Tableau, estimativa de causas jurídicas a partir de digitalizações ruins (visão/OCR) e transcrição de pedidos médicos em códigos de procedimento.

Grupo Boticário | Engenheiro de Software e GenAI (pleno) (jan 2026 – nov 2026)

- **RAG e agentes:** Desenhei um pipeline de RAG sobre materiais de suporte, treinamentos e orientação operacional (banco vetorial, recuperação fundamentada) e implementei agentes com várias ferramentas (consulta a banco, board de tickets, Slack) num harness documentado.
- **Multiplicador de IA:** Selecionado para multiplicar IA na empresa: treinei outros times, orientei boas práticas de implementação de GenAI e destravei squads na adoção.
- **App Super (10.000+ pessoas):** PWA de gestão de força de trabalho (React, Node.js, MongoDB, SSO, AWS EKS) que substituiu dezenas de planilhas: +20% de produtividade dos coordenadores de planta e −10% no tempo de alocação, numa base operacional de ~R$ 63 milhões/ano.

ASSUMTEK (startup) | Engenheiro Full Stack (pleno) e Tech Lead (jan 2025 – jan 2026)

- **Tech lead e plataforma de RH:** Gestão de demanda, arquitetura de solução e 1:1s. Sistema do zero (Node, PostgreSQL, Next.js, Vercel, Railway) para ponto e folha de prestadores, com regras de teto de horas, aprovações e remuneração dinâmica. −70% no tempo de fechamento da folha.
- **Automação e BI:** Integrações (Node.js, n8n, Make) com Meta Ads, CRMs e dados internos, e pipelines em Node.js e Python para Power BI de Produto, Marketing, TI, RH e clientes B2B.

Sentier | Fundador e Engenheiro Full Stack (B2B e SaaS) (jan 2021 – jan 2025)

- **SaaS multi-tenant de barbearia:** Agendamento, folha da equipe, assinaturas e lembretes automáticos (Next.js, Node.js, Prisma, AWS S3, Resend, Vercel). 7.000+ usuários cadastrados; clientes economizaram cerca de 17–20% do tempo operacional diário.
- **B2B de ponta a ponta:** Liderança técnica e engenharia principal em 40+ projetos B2B completos (sistemas, landing pages, automações e BI), do Figma até a produção.

Competências

IA e LLMs: RAG, embeddings e bancos vetoriais (pgvector), LangChain, agentes com várias ferramentas, engenharia de prompt e contexto, OpenAI SDK, Gemini SDK, AWS Bedrock

Serving e operação de LLM: vLLM, LLMs open source (Qwen, Gemma), gateways compatíveis com OpenAI, fallback entre modelos, observabilidade (Langfuse, Grafana), segurança de LLM (OWASP), LGPD

Software: Python, FastAPI, Node.js, TypeScript/JavaScript, React, Next.js, Express, Prisma, PostgreSQL, MongoDB, APIs REST, DDD

Cloud e entrega: AWS (S3, SQS, Lambda, EKS), Docker, CI/CD, Azure DevOps, Vercel, Railway, New Relic, Git Flow

Automação e outros: Make, n8n, Power BI, Figma, Scrum

Em andamento: AWS Bedrock, certificações Anthropic de IA

Formação e cursos

Formação acadêmica

Análise e Desenvolvimento de Sistemas | FAEL (jan 2021 – dez 2025)

Especializações e cursos

- Programa Desenvolve (Full Stack, Node, React, Next, IA) | Grupo Boticário (2025)
- Fundamentos de Negócios | Harvard Business Education (2025)
- Data Analysis e BI | Google (2025)
- Ciência da Computação, CS50x | Harvard University (2021)
- AWS Academy Cloud Foundations | AWS (2021)

Voluntariado

Voluntário do Global Shapers (Fórum Econômico Mundial), treinando professores de escola pública em IA prática e proteção infantil; líder regional e voluntário de TI na Igreja de Jesus Cristo dos Santos dos Últimos Dias (2023–2024); trabalho comunitário com pacientes oncológicos e apoio de web e audiovisual a ONGs.